PROJETO INTEGRADOR · BOLSA FUTURO DIGITAL · DESAFIO TÉCNICO 1

ETL da Distribuidora Vetor

Limpeza, normalização e enriquecimento da base de clientes

[Nomes da equipe] · [Data da apresentação]

Uma base que não permite relatório por bairro

25

grafias diferentes para apenas 4 bairros

34%

dos CEPs ausentes ou zerados (16 de 47)

4

formatos de data e de telefone; CNPJ com e sem máscara

Pipeline em três etapas

Extração

Lê o CSV de 47 clientes.

Transformação

Normaliza bairro, CEP, CNPJ, telefone, data e e-mail. Consulta o ViaCEP (reserva: BrasilAPI) com cache local.

Carga

Grava clientes, vendedores e auditoria no PostgreSQL. Pode ser reexecutada sem duplicar dados.

Como o bairro é decidido

CEP e bairro concordam	Mantém o bairro. A subdivisão (Sul, Norte, I, II) fica em coluna própria.
CEP e bairro divergem	A API prevalece; a divergência é sinalizada e auditada.
Sem CEP utilizável ou inexistente (19 clientes, todo o Guará)	Vale o bairro normalizado pelo dicionário.
Bairro fora do dicionário	Revisão manual; depois o dicionário é ampliado.

"Sul (Águas Claras)" → chave "sul aguas claras" → Águas Claras / Sul · 4

Resultado da execução real

25 → 4

grafias viram bairros canônicos

14

CEPs distintos consultados no ViaCEP; 2 não encontrados

191

linhas de auditoria

0

clientes pendentes de revisão manual

27 clientes confirmados pelo CEP · 1 divergência detectada (CLI0002) · 18 resolvidos só pelo dicionário

Confiabilidade e rastreabilidade

Testes e auditoria

112 testes automatizados, com ViaCEP e BrasilAPI simulados (sem rede).

Cada decisão fica registrada: valor original → valor tratado → critério e fonte.

O que a execução real revelou

A API devolveu nomes fora do dicionário ("Areal", "Setor Habitacional Vicente Pires"): 8 clientes foram para revisão e o dicionário foi ampliado.

Um limite de coluna falhou só no PostgreSQL, não no SQLite dos testes: corrigido e coberto por teste.

Automatizado × manual, e limites

Automatizado

Normalização de texto e dicionário de bairros

Consulta de CEP com cache e provedor reserva

Padronização de CNPJ, telefone e data

Manual ou sinalizado

Bairro fora do dicionário ou aproximado: revisão humana

6 datas ambíguas, lidas como dd/mm e marcadas

47 CNPJs com dígito verificador inválido (base sintética): sinalizados, não descartados

Limites: o dicionário nasceu desta amostra de 47 clientes; "Areal → Águas Claras" é uma premissa documentada.